

Titre du rapport

Nom de l'auteur

31 octobre 2025

1 Introduction à la théorie de la coalescence.

1.1 Kingman coalescent est la limite de Wright-Fisher.

Nous disposons d'une population haploïde¹ de taille N . On commence à la génération $m = 0$ et nous souhaitons remonter le temps pour étudier la généalogie de $n < N$ individus, généralement on considère $n \ll N$. On appelle la lignée de $i \in [n] := \llbracket 1, n \rrbracket$ la suite des ancêtres de i . Lorsque deux, ou plus, lignées choisissent le même parent à un instant donné, on dit qu'elles coalescent.

Formellement, on définit pour la génération $m \in \mathbb{N}$, la relation d'équivalence \sim_m pour tout $i, j \in [n]$,

$$i \sim_m j \text{ ssi les lignées de } i \text{ et } j \text{ ont le même ancêtre à la génération } m$$

La classe de i à la génération m , constituant un bloc, est,

$$C_m^{(N)}(i) := \{j \in [n], i \sim_m j\}$$

Puis, la famille des classes distinctes forme une partition de $[n]$

$$\Pi_m^{(N)} := \{C_m^{(N)}(i), i \in [n]\} \quad K_m := |\Pi_m^{(N)}|$$

Dans le modèle historique de Wright-Fisher, à chaque génération, chaque individu choisit un parent au hasard dans la génération précédente, de manière indépendante et uniforme Fisher [1930], Wright [1931]. On a ainsi que $(\Pi_m^{(N)})_{m \geq 0}$ est une chaîne de Markov homogène à temps discret sur les partitions de $[n]$.

Notons $(\cdot)_k = \prod_{i=-k+1}^0 \cdot$. On a que la probabilité que $k \geq 2$ lignées de b blocs coalescent en une génération est donnée par,

$$\binom{b}{k} \frac{(N)_{b-k+1}}{N^b} = \begin{cases} \binom{b}{2} \frac{1}{N} + \mathcal{O}(\frac{1}{N^2}) & \text{si } k = 2 \\ \mathcal{O}(\frac{1}{N^2}) & \text{si } b \geq k \geq 3 \\ 0 & \text{sinon} \end{cases}$$

On remarque donc que l'évènement d'une coalescence est rare lorsque N est grand. On considère ainsi le processus de Markov $(\Pi^{(N)}(t))_{t \geq 0}$ défini par,

$$\Pi^{(N)} : t \in \mathbb{R}^+ \mapsto \Pi_{\lfloor tN \rfloor}^{(N)}$$

Notons le semi-groupe associé

$$P_t^N : (x, y) \mapsto \mathbb{P}(\Pi^{(N)}(t) = y | \Pi^{(N)}(0) = x)$$

Considérons x une partition de $[n]$ avec k blocs, y une partition de $[n]$, avec $k - 1$ blocs, obtenue en fusionnant deux blocs de x , et y^+ une partition de $[n]$ en fusionnant plus de deux blocs de x . Puisque $t \mapsto P_t^N$ est en escalier, le générateur infinitésimal est donné par,

$$q^{(N)} : (x, z) \mapsto N(P_{1/N}^N(x, z) - \delta_{x,z}) = \begin{cases} N\left(\frac{1}{N} + \mathcal{O}(\frac{1}{N^2}) - 0\right) & = 1 + \mathcal{O}(\frac{1}{N}) & \text{si } z = y \\ N\left(\mathcal{O}(\frac{1}{N^2}) - 0\right) & = \mathcal{O}(\frac{1}{N}) & \text{si } z = y^+ \\ N\left(1 - \binom{k}{2} \frac{1}{N} + \mathcal{O}(\frac{1}{N^2}) - 1\right) & = -\binom{k}{2} + \mathcal{O}(\frac{1}{N}) & \text{si } z = x \end{cases}$$

1. Chaque individu porte une seule copie du génome, modélisée par un unique parent.

En passant à la limite sur N vers l'infini, nous obtenons le coalescent de Kingman Kingman [1982]. Son générateur est donné par,

$$q : (x, z) \mapsto \lim_{N \rightarrow \infty} q^{(N)}(x, z) = \begin{cases} 1 & \text{si } z = y \\ -\binom{k}{2} & \text{si } z = x \\ 0 & \text{sinon} \end{cases}$$

Ce modèle considère uniquement le fait que deux lignées peuvent coalescer à la fois.

1.2 Λ -Coalescent.

Intéressons nous à un cas plus général où un certain nombre de lignées peuvent coalescer simultanément. Nous restons dans l'esprit d'un modèle limite où N tend vers l'infini afin de considérer une proportion $x \in [0, 1]$ de la population descendant d'un même individu. La description du générateur infinitésimal de ce processus de Markov repose sur le théorème suivant,

Théorème 1 (Pitman-Sagitov Pitman [1999], Sagitov [1999]). *Il existe un processus de Markov, appelé Λ -coalescent, échangeable à collisions multiples simples si et seulement s'il existe une mesure finie Λ sur $[0, 1]$ telle que, lorsqu'on a b blocs, pour tout $2 \leq k \leq b$ le taux auquel chaque k -uplet fixé de blocs fusionne vaut,*

$$\lambda_{b,k} = \int_0^1 x^{k-2} (1-x)^{b-k} \Lambda(dx)$$

Sous des hypothèses raisonnables telles que l'absence de mémoire (processus de Markov), la permutation invariante des blocs (échangeabilité) et qu'à chaque instant il ne peut pas y avoir plusieurs coalescences n'ayant pas le même ancêtre (collisions multiples simples), ce résultat montre que la dynamique d'un processus de coalescence multiple est entièrement caractérisée par une mesure finie Λ sur $[0, 1]$.

Dans ce rapport nous simulons différents Λ -coalescents pour différentes mesures Λ et **TODO : dire ce qu'on veut faire réellement que juste faire des plots.**

2 ? ?

Je sais pas si on fait une "liste" de mesure qu'on regarde, je pensais plutôt renrer dans le vif du sujet avec la problématique définie et au fur et à mesure on montre les différents plot avec les différentes mesures testées.

Parler de $\Lambda = \delta_0$: Kingman (dire que la theorie "généralise") + Parler de beta ?

TODO :

- Image vulgarisatrice de ce qu'on fait (j'ai une idée donc à voir si c'est utile)
- Détails des calculs d'Axcel pour différentes mesure : nouvelle section + subsections
- Enchaîner avec une succession de beaux plots
- Lancer une problématique (à en discuter voir où on veut aller : trouver un paramètre par simulation (temps d'un unique ancêtre, pb de coalescence multiple, ...), estimer la distance entre deux modèles (KS, Wasserstein, ...), usage détourné de la coalescence pour faire quelque chose d'atypique)

Références

- Ronald A. Fisher. *The Genetical Theory of Natural Selection*. Clarendon Press, Oxford, 1930.
- Sewall Wright. Evolution in mendelian populations. *Genetics*, 16(2) :97–159, 1931.
- J. F. C. Kingman. The coalescent. *Stochastic Processes and their Applications*, 13(3) :235–248, 1982. doi : 10.1016/0304-4149(82)90011-4.
- Jim Pitman. Coalescents with multiple collisions. *The Annals of Probability*, 27(4) :1870–1902, 1999.
- Serik Sagitov. The general coalescent with asynchronous mergers of ancestral lines. *Journal of Applied Probability*, 36(4) :1116–1125, 1999.